

Science des données 1


TP 1

Cet enseignement a pour objectif de vous initier à la **science des données**, un champ multi-disciplinaire visant à donner du sens à des données brutes. Vous verrez comment combiner des outils provenant des mathématiques, de la statistique et de l'informatique pour charger, nettoyer, traiter et visualiser des données afin de pouvoir en extraire de la connaissance.

Vous allez utiliser des logiciels de **programmation visuelle**. Ce type d'outil permet de créer des programmes complexes en mettant bout à bout des éléments graphiques, chaque élément graphique correspondant à un programme plus simple déjà implémenté. Vous n'aurez donc (quasiment) pas de programmation à faire. L'avantage de ce type d'outil est la rapidité et la simplicité de création des programmes. L'inconvénient est qu'il est forcément limité : il n'existe pas d'élément graphique pour tous les programmes dont vous pouvez avoir besoin. Les enseignements en science des données des prochains semestres porteront donc sur les outils de programmation « classiques ».



Le premier logiciel de programmation visuelle que vous allez manipuler est **orange**¹. C'est un logiciel libre contenant de nombreux programmes permettant de traiter des données brutes. De plus, il est gratuit et disponible sur Linux, Mac OS et Windows : c'est pourquoi nous l'avons choisi pour cet enseignement (pensez à l'ajouter dans votre CV !). A noter cependant qu'il est peu utilisé dans le monde professionnel, dans la mesure où l'ergonomie est pauvre, le nombre de fonctionnalités est limité et il n'offre pas de bonnes performances sur les gros jeux de données. Les entreprises privilégient donc des outils comme *Dataiku*², *RapidMiner*³, *Alteryx*⁴, etc. qui sont malheureusement payant.



La plupart des exercices sur *Orange* qui seront à réaliser dans le cadre de cet enseignement seront librement inspirés des tutoriels en ligne mis à disposition par *Orange* sur une chaîne *Youtube*⁵. Ce premier TP contient 4 exercices de prise en main du logiciel. Le premier vous permettra d'apprendre à charger des données et les visualiser sous forme de tables, de nuages de points et de boîtes à moustache. Vous verrez aussi comment visualiser les distributions. Le deuxième exercice vous présentera des fonctionnalités utiles pour la création de chaînes de traitement. Le troisième exercice portera sur la visualisation des distributions. En manipulant l'outil dédié d'*Orange*, vous devrez répondre à un certain nombre de questions au sujet des données. Enfin, le quatrième exercice sera dédié à l'import de fichiers CSV.

Mots-clés : science des données, programmation visuelle, nuage de points, distribution, boîte à moustaches, données d'entrée d'un programme, données de sortie d'un programme, chaîne de traitement de données.

¹ <https://orangedatamining.com/>

² <https://www.dataiku.com/>


³ <https://rapidminer.com/>

⁴ <https://www.alteryx.com/fr>

⁵ <https://www.youtube.com/channel/UCIKKWBe2SCAEyv7ZNGhIe4g>


Exercice 1

Commencez par télécharger et installer le logiciel Orange⁶. Ensuite, lancez-le :




Comme vous pouvez l'observer, l'interface du logiciel est composée de deux panneaux : le panneau de gauche (*Data, Transform, Visualize...*) contient les différents outils (*ie.* éléments graphiques correspondant à des programmes) de traitement des données et celui de droite (vide ci-dessus) va contenir les traitements que vous allez créer.

Commençons par un exemple simple pour comprendre le fonctionnement du logiciel. Cliquez sur le menu Data dans le panneau de gauche. La liste des outils de gestion des données apparaît :




⁶ <https://orangedatamining.com/download/>

Vous allez maintenant sélectionner le premier outil *File* et l'amener sur le panneau de droite à l'aide d'un glisser-déposer :




L'outil File permet de charger un fichier de données. Double-cliquez dessus et sélectionnez le fichier *iris.tab* (fourni avec le logiciel) :



Vous pouvez observer qu'il contient 150 individus, 4 variables quantitatives (type *numeric*) et une variable qualitative (type *categorical*). Les individus correspondent ici à des fleurs d'iris, la variable qualitative (*iris*) à l'espèce d'iris et les 4 variables quantitatives à la longueur des sépales (*sepal length*), la largeur des sépales (*sepal width*), la longueur des pétales (*petal length*) et la largeur des pétales (*petal width*) :

Info				
Iris flower dataset				
Classical dataset with 150 instances of Iris setosa, Iris virginica and Iris versicolor.				
150 instance(s)				
4 feature(s) (no missing values)				
Classification; categorical class with 3 values (no missing values)				
0 meta attribute(s)				
Columns (Double click to edit)				
	Name	Type	Role	Values
1	sepal length	N numeric	feature	
2	sepal width	N numeric	feature	
3	petal length	N numeric	feature	
4	petal width	N numeric	feature	
5	iris	C categorical	target	Iris-setosa, Iris-versicolo...

Fermez la fenêtre de l'outil *File*. Pour explorer plus en détail les données que contient ce fichier, déplacez l'outil *Data Table* sur le panneau de droite :



Il vous faut maintenant dire à Orange que l'outil *Data Table* doit s'appliquer au fichier chargé grâce à l'outil *File*. Autrement dit, il faut dire que les données d'entrée (*input data*) de *Data Table* correspondent aux données de sortie (*output data*) de *File*. Pour cela, cliquez sur l'arc en pointillés à droite de *File* et dessinez une ligne jusqu'à l'arc en pointillés à gauche de *Data Table* :




Double-cliquez sur l'outil *Data Table* pour l'ouvrir :


	iris	sepal length	sepal width	petal length	petal width
1	Iris-setosa	5.1	3.5	1.4	0.2
2	Iris-setosa	4.9	3.0	1.4	0.2
3	Iris-setosa	4.7	3.2	1.3	0.2
4	Iris-setosa	4.6	3.1	1.5	0.2
5	Iris-setosa	5.0	3.6	1.4	0.2
6	Iris-setosa	5.4	3.9	1.7	0.4
7	Iris-setosa	4.6	3.4	1.4	0.3
8	Iris-setosa	5.0	3.4	1.5	0.2
9	Iris-setosa	4.4	2.9	1.4	0.2
10	Iris-setosa	4.9	3.1	1.5	0.1
11	Iris-setosa	5.4	3.7	1.5	0.2
12	Iris-setosa	4.8	3.4	1.6	0.2
13	Iris-setosa	4.8	3.0	1.4	0.1
14	Iris-setosa	4.2	2.0	1.1	0.1

Vous pouvez ainsi voir les données que contient le fichier. Fermez la fenêtre *Data Table*.

Vous allez maintenant afficher ces données sous la forme d'un **nuage de points**. Pour cela, ouvrez le menu *Visualize* dans le panneau de gauche et ajoutez l'outil *Scatter Plot* à votre panneau de droite. Faites en sorte qu'il prenne en entrée les données de sorte de *File* :




Ouvrez maintenant l'outil *Scatter Plot* (en double-cliquant dessus) :



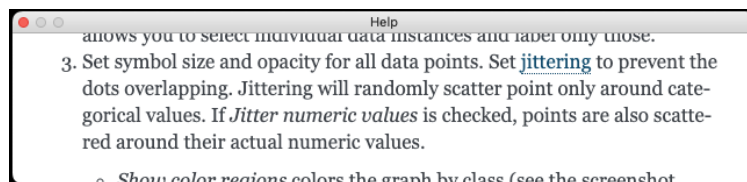
Vous pouvez voir un nuage de points construit à partir des données d'iris. Ici, chaque individu/plante est représenté par un point. Sa position *x* correspond à la valeur de la variable *sepal length* et sa position *y* à la valeur de la variable *sepal width*. En haut à gauche de la fenêtre, vous pouvez modifier les variables des axes. Essayez.

La couleur représente la variable qualitative *iris* (l'espèce d'iris). Il y a 3 espèces, *iris-setosa* (en bleu), *iris-versicolor* (en rouge) et *iris-virginica* (iris-virginica). Vous pouvez observer que certains


points du nuage apparaissent « plus foncés » que d'autres. En réalité, c'est parce que plusieurs points sont superposés à ces positions et qu'une transparence a été appliquée. Jouez avec l'ascenseur *Opacity* dans le panneau de gauche pour faire varier la transparence. Vous pouvez aussi modifier la variable mise sur la couleur dans le panneau de gauche (*color*) ainsi que la forme (*shape*), la taille (*size*) et l'étiquette (*label*). Testez ces différentes options ainsi que celles fournies avec les ascenseurs et les cases à cocher en dessous :



A quoi sert l'option Jittering ? Comment l'utiliser avec des variables quantitatives ? Pour répondre à ces questions, ouvrez la documentation de *Scatter Plot* en cliquant sur le point d'interrogation en bas à gauche :




Pour vous entrainer à manipuler toutes ces options, créez le nuage de points ci-dessous dans laquelle la position x représente la longueur des pétales, la position y leur largeur, la couleur la longueur des sépales, la taille leur largeur, et la forme l'espèce d'iris :




Vous obtenez ainsi une visualisation dans laquelle les 5 variables de votre jeu de données sont représentées.

Revenez maintenant aux options initiales (voir figure précédente). Cliquez sur *Find informative Projections* dans le panneau de gauche, puis sur *Start*. Cette fonctionnalité permet de trouver les deux variables qui séparent au mieux les données en fonction d'une variable cible (dans votre cas, ce sera l'espèce car c'est la seule variable qualitative), et de les représenter sur les axes x et y.


Ici, les deux variables qui séparent au mieux les données en fonction de leur espèce sont *petal length* et *petal width* :



Vous pouvez observer dans le nuage de points que les fleurs de l'espèce *iris-setosa* sont clairement séparées de celles des deux autres espèces. En revanche, il existe une zone dans laquelle sont mélangées de fleurs des espèces *iris-versicolor* et *iris-virginica*. Sélectionnez cette zone à l'aide de votre souris en cliquant dans un de ses coins et en maintenant le bouton enfoncé jusqu'à arriver au coin opposé (les fleurs sélectionnées apparaissent avec une bordure orange) :




Lorsque l'on sélectionne des éléments dans un outil, seuls ces éléments sont envoyés en sortie de l'outil. Pour vous en convaincre, ajoutez un *Data Table* en sortie de *Scatter Plot* :




Ouvrez *Data Table*, vous pouvez observer que seules les fleurs sélectionnées apparaissent.

Vous allez maintenant visualiser les **distributions** des variables en fonction de l'espèce. Ajoutez l'outil *Distributions* (onglet *Visualize*) en sortie de *File* :




Double cliquez dessus, sélectionnez la valeur « normal » pour *Fitted distribution* (on suppose une distribution normale des valeurs) et cochez *Hide bars* :




Vous pouvez ainsi voir la distribution de la variable sélectionnée en haut à gauche (*petal width* dans la figure ci-dessus). Changez de variable (en cliquant dessus en haut à gauche) et observez les différentes distributions, puis fermez la fenêtre *Distributions*.


Vous allez maintenant afficher les données sous la forme de **boîtes à moustaches**. Ajoutez l'outil *Box Plot* (onglet *Visualize*) en sortie de *File* :



Traditionnellement, une boîte à moustache permet de visualiser le minimum, le premier quartile, la médiane, le troisième quartile et le maximum d'une variable quantitative, comme le montre l'image ci-dessous⁷ :




Double cliquez sur l'outil *Box Plot*. Comme vous pouvez l'observer, les boîtes à moustaches proposées par *Orange* représentent d'autres informations. Pour comprendre, commencez par sélectionner *sepal length* dans le champ *Variable* (en haut à gauche), *None* dans le champ *Subgroups* (au milieu à gauche) et *No comparison* dans le champ *Display* (en bas à gauche) :




⁷ https://fr.wikipedia.org/wiki/Bo%C3%A0Ete_%C3%A0_moustaches

Vous obtenez ainsi la boîte à moustache de la variable *sepal length*. On retrouve bien les 5 valeurs représentées par une boîte à moustache « classique » :




Ainsi, on peut voir le 1^{er} quartile de la variable *sepal length* vaut 5,1, que la médiane vaut 5,8, que le 3^{ème} quartile vaut 6,4.

Vous pouvez aussi observer que cette boîte contient en plus un segment bleu foncé vertical (à ne pas confondre avec le segment jaune vertical qui représente la médiane) et un segment bleu horizontal. Le premier représente la moyenne. Elle est ici légèrement supérieure à la médiane (5,843). Le second représente l'écart type (ici $\pm 0,83$) :




Le champ *Variable* en haut à gauche permet de choisir la variable dont la boîte à moustaches est affichée. Testez avec les différentes variables quantitatives puis reprenez *sepal length*.

Dans le champ *Subgroups*, sélectionnez *iris* à la place de *None* : 3 boîtes à moustaches apparaissent :




Chacune correspond aux individus d'une des modalités de la variable *iris*. Par exemple, la première boîte à moustaches représente la variable *sepal length* pour les individus dont la variable *iris* est égale à *Iris-setosa*.

Sélectionnez la variable qualitative (*iris*) en haut à gauche. Dans ce cas, ce n'est pas une boîte à moustaches qui est affichée mais des barres représentant le pourcentage d'individus pour chaque modalité de la variable. Ici, on peut voir que chaque modalité concerne un tiers des individus :



Vous pouvez aussi afficher le nombre d'individus pour chaque modalité en désélectionnant *Stretch bars* dans le champ *Display* :



Vous pouvez voir qu'il y a 50 individus pour chaque modalité.

Fermez la fenêtre de l'outil *Box plot*.

Dans la fenêtre contenant les outils que vous avez utilisés, vous pouvez observer que les mots *Data* et *Selected Data* apparaissent au-dessus des lignes reliant les outils de traitement. Comme vous l'avez vu plus haut, cela signifie que les données issues de l'outil de gauche (**données de sortie du programme** correspondant) sont transmises à l'outil de droite (**données d'entrée du programme** correspondant). Avec *Orange*, on peut soit donner en sortie toutes les données (*Data*), soit une partie des données sélectionnée au préalable (*Selected Data*). En analyse de données, il est courant d'avoir une séquence de programmes dans laquelle chaque programme prend comme données d'entrée les données de sortie du programme précédent. On appelle cela une **chaîne de traitement** (*data analysis workflow*). Vous venez donc de réaliser votre première chaîne de traitement !


Pour finir cet exercice, fermez la fenêtre *Scatter Plot* et enregistrez votre travail (menu *File* -> *Save As ...*) pour le garder comme exemple.

Exercice 2


Ouvrez un nouveau fichier *Orange* (menu *File* -> *New*). Il existe différentes méthodes pour ajouter un outil à votre chaîne de traitement dans le panneau de droite. La première, que vous avez utilisée précédemment, consiste à faire un glisser-déposer depuis le panneau de gauche jusqu'au panneau de droite. Utilisez-là pour ajouter l'outil *File* et chargez le jeu de données *iris.tab* :




La seconde méthode consiste tout simplement à cliquer sur l'outil dans le menu de gauche. Il apparaît ainsi dans le panneau de droite. Testez en ajoutant un *Data Table* :




La troisième méthode consiste à faire un clic droit sur le panneau de droite. Un menu contextuel apparaît et vous permet de sélectionner l'outil que vous voulez ajouter. Utilisez cette fonctionnalité pour ajouter l'outil *Scatter Plot*. Pour le trouver rapidement dans la liste d'outils, vous pouvez utiliser le filtre en y tapant le début de *Scatter Plot*.




La quatrième et dernière méthode consiste à créer une connexion en sortie d'un outil (une ligne) et de la terminer dans un endroit vide du panneau de droite. Un menu contextuel permettant de sélectionner un outil apparaît alors. Utilisez cette méthode pour créer un *Box Plot* en sortie de *File*.



Dans le panneau de droite, les outils peuvent être déplacés à l'aide d'un glisser-déposer. Déplacez-les et ajoutez les connexions de façon à obtenir la chaîne de traitement suivante :




Lorsque vous allez créer des chaînes de traitement complexes, vous allez rapidement être confronté à un manque d'espace dans le panneau de droite. Vous pouvez alors minimiser le panneau de gauche en ouvrant le menu *View* en haut et en désélectionnant *Expand Tool Dock* :




Vous pouvez ensuite ajouter les outils avec la troisième ou la quatrième méthode.

Ouvrez la fenêtre du nuage de points. Comme vous pouvez le voir, toutes les données y sont représentées. Ajoutez maintenant une connexion entre la sortie de *Data Table* et l'entrée de *Scatter Plot* :




Ouvrez la fenêtre de *Data Table* et placez-la à côté de celle de *Scatter Plot*. Dans le *Data Table*, sélectionnez des lignes (cliquez sur une ligne pour en sélectionner une seule, maintenez la touche

Control sous Windows ou *Command* sous MacOS puis cliquez sur les lignes pour en sélectionner plusieurs, cliquez sur une ligne puis maintenez la touche shift enfoncée puis cliquez sur une seconde ligne pour sélectionner la plage entre ces deux lignes). Votre sélection est automatiquement « envoyée » au nuage de points qui met les points correspondants en surbrillance :




Modifiez la sélection et observez comment le nuage de points est mis à jour.

Double-cliquez maintenant sur la connexion reliant *Data Table* et *Scatter Plot*. Une fenêtre indiquant le type de connexion apparaît :




Dans cet exemple, on peut voir que les données de sortie de *Data Table* sont celles qui sont sélectionnées (*Selected Data*) et que *Scatter Plot* les considère comme un sous-ensemble de son jeu de données d'entrée (*Data Subset*). Il met donc ce sous-ensemble en surbrillance mais conserve le reste du jeu de données qu'il récupère grâce à la connexion le reliant à *File*.


Cliquez sur le lien entre *Selected Data* et *Data Subset* pour le supprimer. Remplacez-le par un lien entre *Selected Data* et *Data* puis cliquez sur *OK* :



Maintenant, les données sélectionnées dans *Data Table* constituent l'ensemble du jeu de données pris en entrée par *Scatter Plot*. Le nuage de mot est mis à jour en n'affichant que ces données :



Pour finir, il est aussi possible de supprimer une connexion. Pour cela, faites un clic droit dessus et cliquez sur *Remove* dans le menu qui apparaît. Essayez en supprimant la connexion entre *Data Table* et *Scatter Plot* :




Vous savez maintenant comment réaliser des connexions permettant de faire communiquer les outils entre eux. La plupart du temps, vous n'aurez pas à modifier ces connexions car *Orange* les déduit automatiquement en fonction de l'ordre selon lequel vous avez ajouté les outils. Cette fonctionnalité peut cependant s'avérer parfois utile.

Pour finir cet exercice, fermez la fenêtre *Scatter Plot* et enregistrez votre travail (menu *File* -> *Save As ...*) pour le garder comme exemple.

Exercice 3

Ouvrez un nouveau fichier *Orange* et chargez le jeu de données *titanic.tab* à l'aide de l'outil *File*.



Ce fichier contient un tableau dans lequel chaque ligne correspond à une personne présente sur le Titanic lorsque le bateau a heurté l'iceberg. Pour chaque personne, on a les variables suivantes :

- son statut (*status*) : équipage (*crew*), 1ère classe (*first*), 2ème classe (*second*) ou 3ème classe (*third*),
- son âge (*age*) : adulte (*adult*) ou enfant (*child*),
- son sexe (*sex*) : féminin (*female*) ou masculin (*male*),
- s'il a survécu (*survived*) : non (*no*) ou oui (*yes*).

Titanic dataset
Data from the real Titanic passengers and their survival.


2201 instance(s)
3 feature(s) (no missing values)
Classification; categorical class with 2 values (no missing values)
0 meta attribute(s)

Columns (Double click to edit)


	Name	Type	Role	Values
1	status	categorical	feature	crew,first,second,third
2	age	categorical	feature	adult,child
3	sex	categorical	feature	female,male
4	survived	categorical	target	no,yes

Ajoutez un *Data Table* en sortie de *File* pour voir les données du fichier :

Ajoutez *Distributions* en sortie de *File* :



Double-cliquez sur l'outil *Distributions* pour voir ce qu'il contient :



Essayez de changer la variable sélectionnée (en haut à gauche) et la variable utilisée pour *Split by* afin de comprendre comment marche le graphique. Une fois que c'est fait, répondez aux questions suivantes en choisissant les options qui vous permettent de le faire :

- Le nombre de personnes en 2ème classe est plus grand que le nombre de personnes en 1ère classe, vrai ou faux ?
- Le nombre de membres de l'équipage est plus grand que le nombre de personnes en 3ème classe, vrai ou faux ?
- La plupart des enfants ont survécu, vrai ou faux ?
- La plupart des femmes ont survécu, vrai ou faux ?
- La plupart des hommes ont survécu, vrai ou faux ?
- La plupart des personnes en 1ère classe ont survécu, vrai ou faux ?
- La plupart des personnes en 2ème classe ont survécu, vrai ou faux ?
- Le nombre de personnes de 3ème classe ayant survécu est plus grand que le nombre de personnes de 2ème classe ayant survécu, vrai ou faux ?
- Le taux de survie des personnes de 3ème classe est plus élevé que le taux de survie des personnes de 2ème classe, vrai ou faux ?

Pour finir cet exercice, fermez la fenêtre *Scatter Plot* et enregistrez votre travail (menu *File -> Save As ...*) pour le garder comme exemple.

Exercice 4

Dans les exercices précédents, vous avez chargé des jeux de données directement présents dans *Orange* au format natif du logiciel (*TAB*). Il est cependant possible de charger toutes sortes de fichiers, et en particulier des fichiers contenant des données tabulaires aux formats *Excel* ou *CSV*. Typiquement, ce genre de fichiers se compose d'individus, chaque individu se trouvant sur une ligne, et de variables, chaque variable se trouvant sur une colonne. La première ligne contient les noms des variables. Les autres cellules contiennent les valeurs des variables pour chaque individu :

Sur Moodle, récupérez le fichier *experiment.csv*. Ouvrez-le avec un tableur (*Microsoft Excel*, ou *LibreOffice*) :

	A	B	C	D	E	F
1	id	exactitude	temps de réponse	age	cs	genre
2	1	57,1	1,309	10	classe bourgeoise	F
3	2	55,4	1,148	12	classe moyenne	F
4	3	87,18	1,206	29	classe ouvrière	F
5	4	69,06	0,553	34	classe défavorisée	F
6	5	59,24	0,915	39	classe moyenne	M
7	6	62,39	0,781	32	classe moyenne	F
8	7	65,78	0,935	31	classe moyenne	M
9	8	55,67	0,93	20	classe moyenne	F
10	9	73,3	1,153	32	classe moyenne	M
11	10	62,64	0,718	36	classe moyenne	F
12	11	80,3	1,148	37	classe moyenne	F
13	12	54,45	0,875	22	classe moyenne	M
14	13	70,3	0,92	39	classe moyenne	F
15	14	65,85	1,159	23	classe moyenne	F
16	15	65,38	0,787	37	classe moyenne	M
17	16	54,67	0,701	29	classe moyenne	F

Ici, chaque ligne correspond à une personne ayant répondu à une série de questions. Pour chacune d'entre elles, vous avez son identifiant en colonne A (*id*), son score de bonnes réponses en colonne B (*exactitude*), son temps de réponse moyen en secondes en colonne C (*temps de réponse*), son âge en colonne D (*age*), sa classe sociale en colonne E (*cs*) et son genre en colonne F (*genre*).

Ouvrez maintenant ce fichier avec un éditeur de texte comme, *TextEdit* (*MacOS*) ou *Bloc-notes* (*Windows*) :


```
1 id;exactitude;temps de réponse;age;cs;genre
2 1;57,1;1,309;10;classe bourgeoise;F
3 2;55,4;1,148;12;classe moyenne;F
4 3;87,18;1,206;29;classe ouvrière;F
5 4;69,06;0,553;34;classe défavorisée;F
6 5;59,24;0,915;39;classe moyenne;M
7 6;62,39;0,781;32;classe moyenne;F
8 7;65,78;0,935;31;classe moyenne;M
9 8;55,67;0,93;20;classe moyenne;F
10 9;73,3;1,153;32;classe moyenne;M
11 10;62,64;0,718;36;classe moyenne;F
12 11;80,3;1,148;37;classe moyenne;F
```

Vous pouvez observer que les colonnes sont séparées par des points-virgules. En pratique, même si son format pourrait le laisser suggérer⁸, les colonnes d'un fichier *CSV* peuvent être séparées par d'autres caractères que des virgules. En particulier en français, comme les virgules sont utilisées

⁸ CSV pour *Coma Separated Values*, en français « valeurs séparées par des virgules »


dans les nombres décimaux (des points sont utilisés en anglais à la place), les colonnes sont généralement séparées par des points-virgules. C'est le cas dans cet exemple.

Ouvrez un nouveau fichier *Orange* et chargez le jeu de données *experiment.csv* à l'aide de l'outil *File* :




Comme vous pouvez l'observer dans la liste des variables, *Orange* a correctement reconnu qu'elles sont séparées par des points-virgules. En revanche, il n'a pas réussi à reconnaître des nombres pour les valeurs des variables *exactitude* et *temps de réponse*. Elles sont classées comme textes (*text*) et non comme variables quantitatives (*numeric*), ce qui est probablement dû aux virgules que leurs valeurs contiennent. Si vous double-cliquez sur l'icône **S text**, vous pouvez observer que *Orange* ne vous permet pas de changer en *numeric* : il vous laisse seulement le choix entre *text* et *categorical*. C'est très embêtant dans la mesure où les outils qui font des calculs sur des variables quantitatives ne vont pas pouvoir fonctionner.

Pour résoudre ce problème, vous pouvez utiliser l'outil *CSV File Import* (dans le menu *Data*). Ajoutez-le dans le panneau de droite, ouvrez-le et sélectionnez le fichier *experiment.csv*.



Une fenêtre s'ouvre. Elle vous demande de sélectionner le délimiteur des cellules et le séparateur des décimales des nombres. Spécifiez-lui les bonnes valeurs (pour information, point-virgule se dit « semicolon » en anglais) :



Encoding: Unicode (UTF-8)

Cell delimiter: Semicolon ;

Quote character: "


Number separators: Grouping: , Decimal: ,

Column type: Text

	1	2	3	4	5	6
	id	exactitude	temps de ...	age	cs	genre
1						
2	1	57,1	1,309	10	classe ...	F
3	2	55,4	1,148	12	classe ...	F
4	3	87,18	1,206	29	classe ...	F
5	4	69,06	0,553	34	classe ...	F
6	5	59,24	0,915	39	classe ...	M
7	6	62,39	0,781	32	classe ...	F
8	7	65,78	0,935	31	classe ...	M

Reset Restore Defaults Cancel OK

Cliquer sur le bouton OK, le jeu de données est maintenant correctement chargé. Pour vous en convaincre, créez le nuage de points suivant :



Pour finir cet exercice, enregistrez votre travail (menu *File* -> *Save As ...*) pour le garder comme exemple.