

Science des données

Ce deuxième TP est dédié à la mise en place de chaînes de traitement en vue de produire une classification basée sur un algorithme de *clustering* hiérarchique. Il comporte deux exercices. Le premier consiste à classer des données numériques, le second à classer des données textuelles.

Mots-clés : matrice de distances, *clustering* hiérarchique, dendrogramme, corpus, nuage de mots, mots fréquents, nombre d'occurrences, prétraitement, mots d'arrêt, sacs de mots

Exercice 1

Récupérez le fichier *penguins.csv* depuis Moodle et ouvrez-le à l'aide d'un tableur. Les individus de ce fichier sont des pingouins. Pour chaque pingouin, on a son espèce (*species*), l'île où il a été observé (*island*), son sexe (*sex*), la longueur (*bill_length_mm*) et la profondeur (*bill_depth_mm*) de son bec, la longueur de ses nageoires (*flipper_length_mm*) et la masse de son corps (*body_mass_g*).

Ouvrez un nouveau fichier *Orange*. Chargez le fichier *penguins.csv* grâce à l'outil *File*. Vous pouvez observer qu'il contient 344 instances et vous retrouvez bien les 3 variables qualitatives nominales et les 4 variables quantitatives déjà observées dans le tableur :


Info				
344 instance(s)				
7 feature(s) (0.8% missing values)				
Data has no target variable				
0 meta attribute(s)				
Columns (Double click to edit)				
	Name	Type	Role	Values
1	species	C categorical	feature	Adelie, Chinstrap, ...
2	island	C categorical	feature	Biscoe, Dream, ...
3	bill_length_mm	N numeric	feature	
4	bill_depth_mm	N numeric	feature	
5	flipper_length_...	N numeric	feature	
6	body_mass_g	N numeric	feature	
7	sex	C categorical	feature	FEMALE, MALE

Ajoutez un *Scatter Plot* en sortie de *File* et ouvrez-le. Comme vous pouvez l'observer, vous ne pouvez pas utiliser le bouton *Find Informative Projections* pour sélectionner les deux variables séparant au mieux les données. C'est parce qu'il faut préciser à *Orange* quelle est la variable cible, c'est-à-dire la variable nominale pour laquelle les variables sélectionnées par *Find Informative Projections* séparent au mieux les modalités. Dans l'exemple 1 (les iris), la variable *species* avait été paramétrée pour être la cible. Pour le faire ici, ouvrez *File* et modifiez le rôle de *species* en *target*, puis cliquez sur *Apply* :

	Name	Type	Role	Values
1	species	C categori...	feature	Adelie, Chinstrap, ...
2	island	C categorical	feature	Biscoe, Dream, ...


	Name	Type	Role	Values
1	species	C categori...	target	Adelie, Chinstrap, ...
2	island	C categorical	feature	Biscoe, Dream, ...

Ouvrez à nouveau votre nuage de points. Vous pouvez observer que *species* a automatiquement été utilisé pour colorer les points du nuage. Vous pouvez maintenant cliquer sur *Find Informative Projections* pour obtenir le nuage suivant :



Modifiez les paramètres du nuage de points pour vérifier que vous avez bien assimilé les fonctionnalités vues lors de la séance précédente. Cela vous permettra également de comprendre les données.

Ajoutez maintenant l'outil *Distances* (menu *Unsupervised*) en sortie de *File* pour calculer la **matrice de distances** nécessaire en entrée de l'algorithme de *clustering* :



Ouvrez *Distances* :

The 'Distances' tool configuration window. It has a title 'Distances between'. Under 'Distances between', there are two radio buttons: 'Rows' (selected) and 'Columns'. Below this is a 'Distance Metric' dropdown menu set to 'Euclidean'. At the bottom, there is a checkbox for 'Normalized' which is currently unchecked.

En haut, vous pouvez dire si les distances concernent les lignes entre elles ou les colonnes. Comme dans le fichier CSV chaque ligne correspond à un individu, vous devez sélectionner *row*.


En dessous, vous pouvez sélectionner la mesure de distance qui va être utilisée. Dans le cours, vous avez vu la distance euclidienne pour les données numériques et la distance de Jaccard pour les textes. Vous pouvez ici voir qu'il y en a d'autres disponibles. Ouvrez la documentation (« ? » en bas à gauche de la fenêtre *Distances*) et lisez les définitions de ces distances :

- [Euclidean](#) ("straight line", distance between two points)
- [Manhattan](#) (the sum of absolute differences for all attributes)
- [Cosine](#) (the cosine of the angle between two vectors of an inner product space). Orange computes the cosine distance, which is 1-similarity.
- [Jaccard](#) (the size of the intersection divided by the size of the union of the sample sets)
- [Spearman](#) (linear correlation between the rank of the values, remapped as a distance in a [0, 1] interval)
- [Spearman absolute](#) (linear correlation between the rank of the absolute values, remapped as a distance in a [0, 1] interval)
- [Pearson](#) (linear correlation between the values, remapped as a distance in a [0, 1] interval)
- [Pearson absolute](#) (linear correlation between the absolute values, remapped as a distance in a [0, 1] interval)
- [Hamming](#) (the number of features at which the corresponding values are different)
- [Bhattacharyya distance](#) (Similarity between two probability distributions, not a real distance as it doesn't obey triangle inequality.)

Sélectionnez *Euclidean* (distance euclidienne).

Enfin, vous pouvez sélectionner l'option *Normalized*. Pour l'instant, ne le faites pas, nous verrons plus tard quelles en sont les conséquences. Fermez la fenêtre *Distances*.

Pour visualiser les distances calculées, ajoutez à votre chaîne de traitement l'outil *Distance Matrix* (menu *Unsupervised*) en sortie de *Distances* :




Ouvrez *Distance Matrix* et observez la matrice. En bas, changez *Labels* de *species* en *Enumerate* pour avoir les numéros de lignes (ie des individus/pingouins) au lieu de leur espèce. Plus les cases

sont vertes (resp. blanches), plus les distances entre les deux pingouins sont grandes (resp. petites) :

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19
1		50,278	500,199	919,775	300,252	100,422	125,007	925,106	275,309	500,092	450,033	50,051	550,007	51,054	650,242	50,240	300,329	750,181	475,000
2	50,278		550,075	896,175	350,086	150,091	175,073	875,050	325,122	450,034	500,003	100,197	600,015	6,423	600,152	100,048	350,120	700,101	475,000
3	500,199	550,075		1243,932	200,047	400,042	375,264	1425,002	225,095	1000,017	50,878	450,258	51,670	550,027	1150,023	450,126	200,009	1250,007	76,000
4	919,775	896,175	1243,932		1098,515	972,660	987,193	930,326	1081,579	802,460	1206,193	945,365	1282,716	896,120	825,163	945,276	1098,491	854,671	118,000
5	300,252	350,086	200,047	1098,515		200,046	175,431	1225,005	25,173	800,024	150,185	250,349	250,286	350,017	950,018	250,132	2,844	1050,025	125,000
6	100,422	150,091	400,042	972,660	200,046		26,739	1025,013	175,122	600,007	350,044	51,124	450,086	150,006	750,058	50,410	200,072	850,035	325,000
7	125,007	175,073	375,264	987,193	175,431	26,739		1050,095	150,558	625,077	325,042	75,020	425,007	175,322	775,206	75,142	175,563	875,159	300,000
8	925,106	875,050	1425,002	930,326	1225,005	1025,013	1050,095		1200,014	425,040	1375,033	975,119	1475,060	875,011	275,059	975,057	1225,001	175,046	135,000
9	275,309	325,122	225,095	1081,579	25,173	175,122	150,558	1200,014		775,049	175,183	225,408	275,310	325,053	925,019	225,157	25,524	1025,046	150,000
10	500,092	450,034	1000,017	802,460	800,024	600,007	625,077	425,040	775,049		950,023	550,115	1050,034	450,016	150,400	550,055	800,024	250,100	925,000
11	450,033	500,003	50,878	1206,193	150,185	350,044	325,042	1375,033	175,183	950,023		400,046	100,138	500,043	1100,078	400,004	150,286	1200,065	25,000
12	50,051	100,197	450,258	945,365	250,349	51,124	75,020	975,119	225,408	550,115	400,046		500,015	100,684	700,249	5,215	250,458	800,202	375,000
13	550,007	600,015	51,670	1282,716	250,286	450,086	425,007	1475,060	275,310	1050,034	100,138	500,015		600,084	1200,130	500,029	250,353	1300,091	125,000
14	51,054	6,423	550,027	896,120	350,017	150,006	175,322	875,011	325,053	450,016	500,043	100,684	600,084		600,054	100,262	350,031	700,037	475,000
15	650,242	600,152	1150,023	825,163	950,018	750,058	775,206	275,059	925,019	150,400	1100,078	700,249	1200,130	600,054		700,132	950,016	100,317	107,000
16	50,240	100,048	450,126	945,276	250,132	50,410	75,142	975,057	225,157	550,055	400,004	5,215	500,029	100,262	700,132		250,212	800,118	375,000
17	300,329	750,181	200,009	1098,491	2,844	200,072	175,563	1225,001	25,524	800,024	150,286	250,458	250,353	350,031	950,016	250,212		1050,011	125,000

Vous pouvez par exemple observer que les pingouins 1 et 2 sont très proches (env. 50) alors que les pingouins 8 et 13 sont très éloignés (env. 1475).

Ajoutez maintenant l'outil *Hierarchical Clustering* en sortie de *Distances* pour réaliser votre **clustering hiérarchique**.




Ouvrez *Hierarchical Clustering* pour observer le **dendrogramme** produit par l'algorithme de *clustering*. Comme vous pouvez l'observer, il n'y a pas de claire démarcation entre des groupes de pingouins, il va donc falloir modifier les paramètres. En haut à gauche, le paramètre *Linkage* est initialisé à *Single*. Cela veut dire que, comme dans l'exemple du cours, l'algorithme détermine la distance entre deux *clusters* en prenant la distance entre les deux individus les plus proches (chaque individu étant dans un *cluster* différent). Il existe d'autres méthodes plus adaptées pour calculer la distance entre deux *clusters*. Par exemple, on peut calculer la distance moyenne entre les individus des deux *clusters*. L'avantage est ainsi de fusionner ceux dont les individus sont « en moyenne » les plus proches. Changez *Linkage* en *Average* pour faire ça. Le dendrogramme révèle maintenant 2 gros *clusters* très distincts.




Pour rendre le graphique plus lisible, vous pouvez modifier le niveau de zoom (en bas du menu de gauche) et choisir la profondeur affichée du dendrogramme. Cette fonctionnalité permet de « couper » le dendrogramme de façon à ne pas afficher les mini *clusters* créés par les premiers

regroupements à droite. Essayez avec 6. Comme vous pouvez l'observer, au lieu d'avoir la liste des individus à droite, on a déjà une liste de petits *clusters* :




En cliquant sur les axes gradués en haut ou en bas du dendrogramme, vous pouvez afficher une ligne de coupe. Cliquez au niveau du 800 :




Vous pouvez observer que cette coupe permet d'obtenir 5 *clusters*, dont 2 très petits (*C3* et *C4* ne contiennent qu'un seul individu). A l'aide d'un glisser-déposer de la ligne de coupe, arrangez-vous pour afficher 2, 7 puis 9 *clusters*. Dans le menu de gauche, cadre *Selection*, vous avez aussi la possibilité de sélectionner un ratio de la taille du dendrogramme pour afficher la ligne de coupe à xx% de l'axe x ou de choisir un nombre de *clusters* (la ligne de coupe se met alors automatiquement à jour). Testez ces différentes options.


Revenez à la ligne de coupe positionnée à 800 à l'aide d'un glisser-déposer. Cliquez au centre du *cluster 1 (C1)* Cela permet de le sélectionner (il est le seul à apparaître coloré) :



Sans fermer la fenêtre *Hierarchical Clustering*, revenez à votre chaîne de traitement et ajoutez un *Scatter Plot* prenant en entrée *Hierarchical Clustering* (pour récupérer les données sélectionnées) et *File* (pour récupérer l'ensemble des données). Modifiez les connexions si nécessaire :




Ouvrez *Scatter Plot* et cliquez sur *Find Informative Projections* :



Comme vous pouvez l'observer, beaucoup d'individus du *cluster* se trouvent à gauche et sont de l'espèce *Gentoo*. En revanche, il existe aussi beaucoup d'individus des deux autres espèces dans le *cluster*. Ceci n'est pas étonnant. Alors que le nuage de point affiche les deux variables (en x et en y) permettant au mieux de séparer les données en fonction de l'espèce, le *clustering* capture des groupes sur toutes les variables. Changez l'axe x de façon à y afficher la variable *body_mass_g*. Vous pouvez voir ainsi que les individus du *cluster* 1 sont beaucoup plus regroupés. On peut donc dire que le *cluster* 1 regroupe les individus de masse moyenne.

Sans fermer le *Scatter Plot*, cliquez sur le *cluster* 2 dans *Hierarchical Clustering* :



Cette fois, on peut observer qu'il contient les individus dont la masse est élevée. La masse semble donc être prépondérante dans la façon dont les *clusters* sont créés. Ils ne nous apprennent ainsi que peu de choses sur les données. Ceci est dû au calcul des distances et au fait que dans le fichier de données, la colonne masse contient des valeurs beaucoup plus élevées que les autres variables.

Cette variable a donc une plus grande influence que les autres sur la matrice de distances. Pour résoudre ce problème, ouvrez *Distances* et cliquez sur *Normalized* pour normaliser les valeurs de chaque variable pour rendre ces dernières comparables (si vous ne l'avez pas déjà vu, vous apprendrez ça dans vos cours de statistique) :




Vous pouvez maintenant observer le nouveau dendrogramme et cliquer sur les différents *clusters* pour voir comment ils se répartissent dans le nuage de points.


Pour finir cet exercice, enregistrez votre travail (menu *File* -> *Save As ...*) pour le garder comme exemple.

Exercice 2

Dans ce deuxième exercice, nous allons manipuler des textes. Avant toute chose, vous allez devoir ajouter un module complémentaire de traitement de données textuelles. Pour cela, ouvrez *Orange*, puis cliquez sur le menu *Options -> Add-on...* La fenêtre ci-dessous apparaît :




Sélectionnez *Text* et cliquez sur *OK*. Une fois que l'installation est terminée, redémarrez *Orange*, vous pouvez observer qu'un nouveau menu appelé *Text Mining* est apparu dans le panneau de gauche :



Ouvrez ce menu et ajoutez l'outil *Corpus* à votre chaîne de traitement :



Comme son nom l'indique, l'outil *Corpus* permet de charger un **corpus** de textes, *ie* un ensemble de documents réunis en vue de les analyser. Double-cliquez dessus et chargez *grimm-tales-selected.tab* (déjà présent dans *Orange*) :




Ce fichier contient un tableau, chaque ligne correspondant à un conte des frères Grimm. Pour chaque conte, on connaît :

- Son sujet ATU¹ (*ATU topic*),
- Son titre (*Title*),
- Son résumé (*Abstract*),
- Son texte (*Content*),
- Son indice ATU (*ATU Numerical*),
- Son type ATU (*ATU Type*).

Voici les premières lignes de ce fichier lorsqu'on l'ouvre avec un tableur :

	A	B	C	D	E	F
1	ATU Topic	Title	Abstract	Content	ATU Numerical	ATU Type
2	Tales of Magic	A Tale About the Boy Who Went For	A simple boy who just wan	A certain father had two sc	326.0	Supernatural Adversaries
3	Tales of Magic	Brier Rose	An offended witch curses a	A king and queen once upo	410.0	Supernatural or Enchanted Relatives
4	Animal Tales	Cat and Mouse in Partnership	A mouse lives with a cat, a	A certain cat had made the	15.0	Wild Animals
5	Tales of Magic	Cinderella	The familiar story of a girl	The wife of a rich man fell	510A	Supernatural Helpers
6	Tales of Magic	Hansel and Gretel	A poor woodcutter can affc	Hard by a great forest dwe	327A	Supernatural Adversaries
7	Animal Tales	Herr Korbes	A hen and a rooster go visi	Once upon a time there w	210.0	Domestic Animals
8	Tales of Magic	Jorinda and Jorindel	A witch lures young maide	There was once an old cas	405.0	Supernatural or Enchanted Relatives
9	Tales of Magic	Little Red Riding Hood	A girl known for wearing h	Once upon a time there w	333.0	Supernatural Adversaries
10	Tales of Magic	Mother Holle	A widow spoils her daught	Once upon a time there w	480.0	Supernatural Tasks

Afin de voir le contenu du corpus, ajoutez l'outil *Corpus Viewer* (menu *Text Mining*) en sortie de *Corpus* :



¹ https://en.wikipedia.org/wiki/Aarne%E2%80%93Thompson%E2%80%93Uther_Index

Corpus Viewer

Info

Tokens: n/a

Types: n/a

Matching documents: 44/44

Matches: n/a

Search features

- ☒ ATU Topic
- ☐ Title
- ☐ Abstract
- ☐ Content
- ☐ ATU Numerical

Display features

- ☒ ATU Topic
- ☒ Title
- ☒ Abstract
- ☒ Content
- ☒ ATU Numerical

☐ Show Tokens & Tags

☒ Auto send is on

RegExp Filter:

1	A Tale About the Boy ...
2	Brier Rose
3	Cat and Mouse in ...
4	Cinderella
5	Hansel and Gretel
6	Herr Korbes
7	Jorinda and Jorindel
8	Little Red Riding Hood
9	Mother Holle
10	Old Sultan
11	Pack of Scoundrels
12	Rapunzel
13	Rumpelstiltskin
14	Snow White

ATU Topic: Animal Tales

Title: Cat and Mouse in Partnership

Abstract: A mouse lives with a cat, and the cat eats all the fat.

Content: A certain cat had made the acquaintance of a mouse, and had said so much to her about the great love and friendship she felt for her, that at length the mouse agreed that they should live and keep house together. 'But we must make a provision for winter, or else we shall suffer from hunger,' said the cat; 'and you, little mouse, cannot venture everywhere, or you will be caught in a trap some day.' The good advice was followed, and a pot of fat was bought, but they did not know where to put it. At length, after much consideration, the cat said: 'I know no place where it will be better stored up than in the church, for no one dares take anything away from there. We will set it beneath the altar, and not touch it until we are really in need of it.' So the pot was placed in safety, but it was not long before the cat had a great yearning for it, and said to the mouse: 'I want to tell you something, little mouse; my cousin has brought a little son into the'


44 1 | 43 | 44

The diagram illustrates the relationship between a Corpus, Word Cloud, and Corpus Viewer. A central node labeled 'Corpus' (represented by a document icon) is connected to two other nodes: 'Word Cloud' (represented by a cloud icon) and 'Corpus Viewer' (represented by a magnifying glass icon). Both connections are labeled 'Corpus'.


[illegible]

11


(he, she...), ... Il va donc falloir « nettoyer » le corpus avant de réaliser le nuage de point. C'est l'étape de **prétraitement** vue en cours. Pour cela, ajoutez l'outil *Preprocess Text* (menu *Text Mining*) en sortie de *Corpus* :



Double cliquez sur *Preprocess Text* :




Il commence par transformer toutes les majuscules en minuscules (cadre *Transformation* -> *Lowercase*), ainsi les mots *King* et *king* deviennent équivalents. Ensuite il transforme les textes en listes de mots et supprime les signes de ponctuation (cadre *Tokenization*). Enfin, il supprime les **mots d'arrêt** (aussi appelés mots vides), *ie* les mots très fréquents dans n'importe quel texte et qu'il n'est pas intéressant de traiter, comme « a », « the », « is », « are », « he », « she »... (cadre *Filtering*). Si l'on sélectionne *French* à la place d'*English*, il supprimera des mots tels que « le », « la », « du », « ce » ...



Ouvrez ce nuage de mots :



Vous pouvez observer que les signes de ponctuation et les mots d'arrêt n'apparaissent plus. Le nuage de mots est ainsi plus intéressant mais pas encore optimal pour caractériser le corpus. En effet, il reste des mots tels que « could », « would », « said » qui ne présentent pas un grand intérêt. Il va falloir les ajouter manuellement à la liste des mots d'arrêt. Pour cela, ouvrez un éditeur de texte (bloc note, notepad++, atom...) et ajoutez les mots que vous voulez supprimer, un par ligne :



Le nuage de mots est automatiquement mis à jour :



Comme vous l'avez vu en cours, un algorithme de *clustering* prend en entrée une **matrice de distances** qui peut être calculée grâce à des **sacs de mots**. Commencez donc par créer des sacs de mots. Ajoutez l'outil *Bag of Words* (menu *Text Mining*) en sorte de *Preprocess Text* :




Vous pouvez observer les résultats de l'outil *Bag of Words* en utilisant l'outil *Data Table* (menu *Data*) :




En ouvrant *Data Table*, vous pouvez observer que les sacs de mots des textes apparaissent dans une nouvelle colonne (la dernière). On peut y voir l'ensemble des mots du texte avec leur nombre d'occurrences. Par exemple, le mot *able* apparaît une fois dans le premier texte, le mot *ale* apparaît trois fois dans le second texte :

Data Table									
Info									
44 instances 3716 features (sparse,density 8.22 %) Target with 2 values 5 meta attributes									
Variables									
☒ Show variable labels (if present) ☐ Visualize numeric values ☒ Color by instance classes									
Selection									
☒ Select full rows									
Restore Original Order									
☒ Send Automatically									
bow-feature hidden include skip-normalization title	Topic	Title	Abstract	Content	ATU Numerical	ATU Type	{...}		
1	f Magic	A Tale About...	A simple boy...	A certain fat...	326.0	Supernatural...	able=1,accord=1,actually=1,afraid=1,ag...		
2	f Magic	Brier Rose	An offended ...	A king and q...	410.0	Supernatural...	ale=3,alone=1,also=2,altogether=1,ami...		
3	Tales	Cat and Mou...	A mouse live...	A certain cat...	15.0	Wild Animals	absence=1,acquaintance=1,advice=1,a...		
4	f Magic	Cinderella	The familiar ...	The wife of a...	510A	Supernatural...	_my_=1,afterwards=1,almost=1,also=1,...		
5	f Magic	Hansel and ...	A poor wood...	Hard by a gr...	327A	Supernatural...	able=1,across=3,add=1,afar=1,afterwar...		
6	Tales	Herr Korbes	A hen and a ...	Once upon a...	210.0	Domestic An...	aboard=2,afterward=1,along=1,answere...		
7	f Magic	Jorinda and ...	A witch lures...	There was o...	405.0	Supernatural...	_jug=1,alas=2,almost=1,alone=1,alread...		
8	f Magic	Little Red Ri...	A girl known ...	Once upon a...	333.0	Supernatural...	able=1,act=1,afraid=1,afterwards=1,ag...		
9	f Magic	Mother Holle	A widow spo...	Once upon a...	480.0	Supernatural...	according=1,afraid=2,ago=2,agreed=1,...		
10	Tales	Old Sultan	A farmer dec...	A shepherd ...	101.0	Wild Animal ...	accordingly=1,advice=1,afterwards=1,a...		
11	Tales	Pack of Sco...	A rooster an...	The rooster ...	210.0	Domestic An...	able=2,accept=1,across=2,ado=1,agree...		
12	f Magic	Rapunzel	The classic s...	There were ...	310.0	Supernatural...	afraid=1,afterwards=1,agreed=1,ah=3,a...		
13	f Magic	Rumpelstilts...	A miller's da...	By the side o...	500.0	Supernatural...	alas=1,alone=2,among=1,arms=1,asked...		
14	f Magic	Snow White	The classic s...	There was o...	426.0	Supernatural...	account=1,accursed=1,acquaintance=1,...		
15	f Magic	The Blue Light	A wounded s...	There was o...	562.0	Supernatural...	advice=1,aha=1,allowed=1,alone=1,alre...		
16	Tales	The Bremen ...	A donkey,a d...	An honest fa...	130.0	Wild Animal ...	abode=1,according=1,added=1,afar=2,...		
17	Tales	The Crumbs ...	A man tells h...	One day the ...	236.0	Other Anima	anything=2,beat=1,beating=1,began=1...		

Grâce aux sacs de mots, vous allez pouvoir calculer une matrice de distances entre les documents. Pour cela, ajoutez l'outil *Distances* (menu *Unsupervised*) à votre chaîne de traitement :



Double-cliquez ensuite sur *Distances* pour que la mesure utilisée soit la similarité cosinus (*Cosine*), distance très utilisée en fouille de texte² :




Pour voir le résultat de *Distances*, ajoutez *Distance Matrix* (menu *Unsupervised*) en sortie de *Distances*. Double cliquez dessus. Vous pouvez voir que vous avez une matrice avec 44 lignes et 44 colonnes (44 est le nombre de documents dans le corpus) et dans laquelle chaque case contient une distance entre deux textes :


	Tales of Magic	Tales of Magic	Animal Tales	Tales of Magic	Tales of Magic	Animal Tales	Tales of Magic	Tales o
Tales of Magic		0,609	0,754	0,596	0,635	0,834	0,664	0,763
Tales of Magic	0,609		0,821	0,598	0,692	0,866	0,660	0,726
Animal Tales	0,754	0,821		0,775	0,785	0,820	0,822	0,833
Tales of Magic	0,596	0,598	0,775		0,675	0,854	0,701	0,765
Tales of Magic	0,635	0,692	0,785	0,675		0,850	0,769	0,701
Animal Tales	0,834	0,866	0,820	0,854	0,850		0,884	0,853
Tales of Magic	0,664	0,660	0,822	0,701	0,769	0,884		0,823
Tales of Magic	0,763	0,726	0,833	0,765	0,701	0,853	0,823	
Tales of Magic	0,683	0,673	0,801	0,591	0,678	0,865	0,706	0,777
Animal Tales	0,730	0,734	0,728	0,753	0,733	0,881	0,755	0,689
Animal Tales	0,735	0,763	0,826	0,741	0,771	0,560	0,788	0,824
Tales of Magic	0,655	0,693	0,793	0,679	0,745	0,897	0,759	0,836

² https://fr.wikipedia.org/wiki/Similarit%C3%A9_cosinus

Vous pouvez maintenant ajouter l'outil *Hierarchical Clustering* (menu *Unsupervised*) en sortie de *Distances* :




Ouvrez *Hierarchical Clustering*, vous pouvez observer le dendrogramme. Dans le cadre *Linkage*, sélectionnez *Ward* (cet indice basé sur la variance intra-cluster donne généralement des résultats plus exacts que celles vues précédemment ³). Voici le dendrogramme que vous devez obtenir (pensez afficher tous les niveaux et mettez comme étiquette -*Annotations*- la variable *ATU Topic*) :



³ https://fr.wikipedia.org/wiki/M%C3%A9thode_de_Ward


Dans le dendrogramme, placez la ligne de coupe de façon à visualiser les 2 *clusters* principaux :




Comme vous pouvez l'observer, le *cluster 2* ne contient que des contes d'animaux et le *cluster 1* ne contient que des contes de magie sauf un. Afin de comprendre pourquoi un des contes n'a pas été classé correctement par l'algorithme, sélectionnez le *cluster* correspondant en cliquant dessus :



Ensuite, ajoutez à votre chaine de traitement l'outil *Corpus Viewer* :



Comme vous pouvez le voir, grâce à la sélection du *cluster*, *Corpus Viewer* prend en entrée seulement le *cluster* sélectionné et non l'ensemble du corpus. Vous pouvez ainsi, en ouvrant *Corpus Viewer*, voir le conte et déterminer pourquoi il a été classé parmi les contes de magie :



Pour finir, vous pouvez comparer les nuages de mots des deux *clusters* principaux pour voir quels sont les mots qui sont importants dans chacun d'entre eux. Pour cela, ajoutez un *Word Cloud* en sortie de *Hierarchical Clustering* :



Dans le *Hierarchical Clustering*, sélectionnez le *cluster* du haut et ouvrez le *Word Cloud* :



On voit ici que les textes du premier *cluster* parlent de rois, de pères, de mères, de princesses. Cliquez maintenant sur l'autre *cluster*. Le nuage de mots est automatiquement mis à jour :



Dans ce second *cluster*, on trouve, parmi les mots les plus fréquents, des noms d'animaux (chat, chien, loup, souris).

Pour finir cet exercice, enregistrez votre travail (menu *File* -> *Save As ...*) pour le garder comme exemple.